

模型参数

1. 常见超参数及其作用

1.1 学习率 (Learning Rate)

- 作用：控制参数更新的步长
- 常用范围：0.1 ~ 1e-5
- 建议：
 - 从较大值开始尝试，逐步减小
 - 配合学习率衰减策略使用

1.2 批量大小 (Batch Size)

- 作用：每次训练更新中使用的样本数量
- 常用值：32, 64, 128, 256
- 论文示例：
ResNet: 256
Transformer: 2048 tokens
- 建议：
小批量 (32-256) 一般泛化更好
大批量可提升训练速度但风险过拟合

1.3 训练轮数 (Epochs)

- 作用：完整遍历训练集的次数
- 设置范围：
 - 小型数据集：50~200
 - 大型数据集：10~50
- 技巧：
 - 搭配 Early Stopping 使用
 - 实时监控验证损失

1.4 优化器 (Optimizer)

- **常见选择:**
 - SGD、SGD + Momentum (动量 0.9)
 - Adam (默认 $\beta_1=0.9$, $\beta_2=0.999$)
 - AdamW (改进版, 更适用于 Transformer)
- **趋势:**
 - 经典模型: SGD
 - 现代模型: Adam / AdamW

1.5 正则化参数 (Regularization)

- **权重衰减 (Weight Decay):**
 - 抑制过拟合, 常设为 $1e-4$ 或 0.01 (AdamW)
- **Dropout:**
 - 防止神经元共适应, 常设为 $0.1\sim0.5$
 - 输入层 $0.1\sim0.2$, 隐藏层 0.5

2. 网络结构相关参数

2.1 层数与神经元 数量

CNN: 从 LeNet(几层) 到 ResNet(上百层)

Transformer: $6 \sim 24$ 层

每层维度: $32 \sim 4096$ 不等

2.2 激活函数

ReLU: 最常见, 简单有效

LeakyReLU: 缓解“死亡 ReLU”

GELU: Transformer 默认激活

Sigmoid / Tanh: 历史悠久, 但易梯度消失

3. 参数调优策略

3.1 超参数搜索方法

网格搜索 (Grid Search): 全排列遍历参数组合

随机搜索 (Random Search): 效率更高, 更推荐

3.2 动态调整策略

学习率预热 (Warmup)

余弦退火 (Cosine Annealing)

周期性学习率 (Cyclic LR)

版权声明: 本文为 CSDN 博主「Xiaok1018」的原创文章, 遵循 CC 4.0 BY-SA 版权协议, 转载请附上原文出处链接及本声明。

原文链接: https://blog.csdn.net/weixin_67251822/article/details/147193594